

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG
— o0o —



**Hợp nhất mô hình Qwen3 cho tóm tắt văn
bản đa miền bằng chứng cất tri thức**

Project 2

Giảng viên hướng dẫn: Lê Thanh Hương
Sinh viên thực hiện: Võ Hữu Trí Dũng
MSSV: 20235057
Ngành: Khoa học Máy tính K68

Hà Nội - 2026

Mục lục

Lời cảm ơn	3
Tóm tắt	4
1 Giới thiệu	5
2 Các công trình liên quan	7
3 Cơ sở lí thuyết	8
4 Giới hạn của nhóm phương pháp hợp nhất mô hình không sử dụng dữ liệu	9
4.1 Giới hạn đối với các mô hình cố định	9
4.2 Giới hạn đối với các mô hình học	10
5 Phương pháp: ProDistill	11
5.1 Hợp nhất mô hình dưới góc nhìn Chứng cất tri thức	11
5.2 Thuật toán ProDistill	12
6 Thực nghiệm và đánh giá	14
6.1 Thiết lập thực nghiệm	14
6.2 Kết quả thực nghiệm	15
6.3 Phân tích bổ sung	16
6.3.1 Hiệu quả sử dụng dữ liệu	16
6.3.2 Hiệu quả tính toán	17
7 Kết luận	19

LỜI CẢM ƠN

Báo cáo này là kết quả của quá trình tự nghiên cứu, triển khai và thử nghiệm trong khuôn khổ đề án Project 2. Đề tài của em được xây dựng dựa trên ý tưởng và cảm hứng từ công trình **Scalable Model Merging with Progressive Layer-wise Distillation** [20]. Bài báo này đã mang đến cho em một góc nhìn thực tiễn về việc áp dụng kỹ thuật chưng cất tri thức trong việc hợp nhất các mô hình ngôn ngữ trên các tác vụ khác nhau, từ đó giúp định hướng và là nền tảng khoa học cho đề án.

Em xin chân thành cảm ơn cô **Lê Thanh Hương** – giảng viên phụ trách học phần Project 2, đã tạo điều kiện và định hướng học thuật để em thực hiện đề tài này. Những buổi họp và góp ý từ cô là nguồn động lực quan trọng giúp em hoàn thiện báo cáo và triển khai huấn luyện mô hình hiệu quả.

Trong quá trình thực hiện, em đã cố gắng hoàn thiện báo cáo một cách nghiêm túc và đầy đủ nhất. Tuy nhiên, do giới hạn về thời gian và kinh nghiệm, báo cáo chắc chắn vẫn còn tồn tại những thiếu sót. Em rất mong nhận được sự góp ý từ cô để hoàn thiện hơn trong tương lai.

Em xin chân thành cảm ơn!

TÓM TẮT

Hợp nhất mô hình (Model Merging) là phương pháp hiệu quả cho phép tích hợp năng lực của nhiều mô hình đã được tinh chỉnh. Tuy nhiên, sự sụt giảm hiệu năng của mô hình sau hợp nhất vẫn là một thách thức lớn. Trong bài báo gốc, trước hết tác giả nhấn mạnh tính cần thiết của dữ liệu đối với bài toán hợp nhất mô hình, thông qua việc chứng minh rằng các thuật toán hợp nhất không sử dụng dữ liệu có thể dẫn tới hiệu năng tệ tùy ý trong trường hợp xấu nhất. Dựa trên nhận định này, tác giả nghiên cứu mối quan hệ giữa hợp nhất mô hình và kỹ thuật chưng cất tri thức (Knowledge Distillation), từ đó đề xuất một thuật toán hợp nhất mới mang tên PRODISTILL (*Progressive Layer-wise Distillation*). Trái với quan niệm phổ biến cho rằng huấn luyện theo từng tầng làm suy giảm hiệu năng, tác giả chỉ ra rằng cơ chế chưng cất theo từng tầng không những cải thiện khả năng mở rộng mà còn nâng cao hiệu quả hợp nhất mô hình. Em đã tiến hành các thực nghiệm và thấy rằng, so với các phương pháp hợp nhất hiện có, PRODISTILL đạt hiệu năng tốt nhất với tác vụ sinh ngôn ngữ tự nhiên được thực nghiệm, cụ thể là tóm tắt văn bản trên nhiều miền khác nhau. Những kết quả này cho thấy chiến lược hợp nhất mô hình thông qua chưng cất tri thức là một hướng tiếp cận hiệu quả và thực tiễn cho việc hợp nhất các mô hình ngôn ngữ trong bối cảnh tài nguyên hạn chế, đồng thời chứng minh tính khả thi của phương pháp trong phạm vi đề án học phần. Mã nguồn và dữ liệu được công khai tại: <https://github.com/vohuutridung/IT3930>.

Chương 1

Giới thiệu

Những năm gần đây, các mô hình tiền huấn luyện đã tạo ra bước đột phá trong lĩnh vực học sâu, đạt nhiều thành công nổi bật trên các miền ứng dụng như xử lý ngôn ngữ tự nhiên [3] và thị giác máy tính [5]. Đồng thời, ngày càng nhiều các mô hình tinh chỉnh được công bố công khai trên các nền tảng như HuggingFace. Tùy thuộc vào tập dữ liệu huấn luyện downstream, các mô hình tinh chỉnh có thể thể hiện năng lực chuyên biệt ở tác vụ đó, cụ thể như hỏi đáp, dịch máy. Tuy nhiên, các bài toán phức tạp trong thực tế thường đòi hỏi sự kết hợp của nhiều năng lực khác nhau. Mặc dù học đa nhiệm (multi-task learning) [4] có thể giải quyết vấn đề này, nhưng phương pháp này yêu cầu nhiều dữ liệu huấn luyện cũng như phát sinh chi phí tính toán lớn trong quá trình huấn luyện lại. Trong khi đó, sử dụng đồng thời nhiều mô hình (model ensembling) [11] tránh được việc huấn luyện lại nhưng gặp vấn đề về chi phí lưu trữ khi triển khai.

Hợp nhất mô hình (model merging) [23] đưa ra một hướng tiếp cận hiệu quả nhằm giải quyết các thách thức trên. Nghiên cứu [7] chỉ ra rằng độ sai khác giữa trọng số của mô hình tinh chỉnh và mô hình tiền huấn luyện, được gọi là *task vectors*, liên quan đến sự thay đổi năng lực của mô hình. Nhờ đó, các mô hình có thể được hợp nhất thông qua trung bình của các trọng số, dựa trên tính chất kết nối tuyến tính [6] của mạng nơ-ron. Tuy nhiên, hiệu năng của phương pháp hợp nhất này có thể suy giảm, đặc biệt số lượng mô hình tăng lên.

Các nghiên cứu gần đây [14] đã đề xuất nhiều phương pháp nhằm khắc phục vấn đề này, nhiều trong số đó yêu cầu một tập *few-shot validation* chứa thông tin đặc thù của các tác vụ downstream. Điều này lại mâu thuẫn với bản chất không sử dụng dữ liệu (data-free) của phương pháp task arithmetic. Từ đó, bài báo đặt ra câu hỏi:

Liệu dữ liệu đặc thù miền có thực sự cần thiết cho hợp nhất mô hình hay không?

Thông qua phân tích lý thuyết, bài báo đưa ra khẳng định như sau. Trước tiên, tác giả chứng minh rằng trong trường hợp xấu nhất, hiệu năng của bất kỳ thuật toán hợp nhất mô hình không sử dụng dữ liệu nào cũng có thể giảm nghiêm trọng, ngay cả đối với các mô hình tuyến tính đơn giản. Do đó, mặc dù các phương pháp data-agnostic đã đạt nhiều thành công, việc giả định cần thiết một bộ dữ liệu few-shot vẫn là phù hợp


xét về mặt lý thuyết.

Dựa trên các phân tích này, bài báo tiếp tục đi đến câu hỏi thứ hai:

Làm thế nào để tận dụng hiệu quả dữ liệu và các mô hình tinh chỉnh nhằm cải thiện hiệu năng của mô hình hợp nhất?

Để giải quyết thách thức này, bài báo tiếp cận hợp nhất mô hình dưới góc nhìn chưng cất tri thức, trong đó tri thức từ các mô hình tinh chỉnh (teachers) được chuyển giao sang mô hình hợp nhất (student). Tuy nhiên, việc áp dụng trực tiếp thuật toán distillation với thiết lập nhiều teacher dẫn đến chi phí bộ nhớ rất lớn trong quá trình huấn luyện, đặc biệt với các mô hình ngôn ngữ lớn.

Từ đây, tác giả đề xuất thuật toán mới mang tên PRODISTILL (*Progressive Layer-wise Distillation*). PRODISTILL thực hiện chưng cất thông qua chiến lược *activation matching*, trong đó các hệ số hợp nhất được tối ưu nhằm giảm khoảng cách của biểu diễn giữa các mô hình teacher và student. Quá trình huấn luyện được thực hiện theo từng tầng [2], giúp cải thiện chi phí tính toán so với huấn luyện end-to-end truyền thống.



Hình 1.1: Minh họa của ProDistill.

Em tiến hành nhiều thực nghiệm để đánh giá hiệu quả của PRODISTILL. Kết quả cho thấy phương pháp này vượt trội so với các baseline có huấn luyện và không huấn luyện, với mức cải thiện rõ rệt trên tác vụ sinh ngôn ngữ tự nhiên thực nghiệm. Ngoài ra, PRODISTILL còn cho thấy hiệu quả cao về dữ liệu huấn luyện, hiệu năng tính toán, và chi phí bộ nhớ.

Cấu trúc báo cáo được trình bày như sau: Chương 2 trình bày các công trình liên quan về các phương pháp hợp nhất mô hình cũng như chưng cất tri thức. Chương 3 mô tả cơ sở lý thuyết cho bài toán, trước khi Chương 4 nêu ra những hạn chế của lớp phương pháp hợp nhất không sử dụng dữ liệu về mặt lý thuyết. Từ đây, Chương 5 trình bày phương pháp chính PRODISTILL. Chương 6 mô tả chi tiết thiết lập thực nghiệm và phân tích kết quả. Cuối cùng, Chương 7 đưa ra kết luận và các hướng phát triển trong tương lai.

Chương 2

Các công trình liên quan

Hợp nhất mô hình (Model Merging)

Trung bình trọng số là một phương pháp hiệu quả và được sử dụng rộng rãi trong bài toán hợp nhất mô hình [8]. Để cải tiến hiệu quả của phương pháp này, một nhánh nghiên cứu tập trung vào việc giảm xung đột và tăng khả năng tách biệt giữa các *task vectors*, thông qua các kỹ thuật làm thưa (*sparsification*) [19] hoặc phân rã (*decomposition*) [18]. Một hướng tiếp cận khác [15] sử dụng huấn luyện tuyến tính hóa (*linearized training*) nhằm áp đặt tính tuyến tính một cách tường minh trong quá trình hợp nhất mô hình.

Bên cạnh đó, nhiều nghiên cứu tập trung vào việc lựa chọn hệ số hợp nhất tối ưu (*merging coefficients*), bao gồm các phương pháp có huấn luyện [24] hoặc không huấn luyện [14].

Ngoài các phương pháp hợp nhất tĩnh, một số nghiên cứu khác [16] đề xuất cơ chế hợp nhất động thông qua định tuyến theo tác vụ và kiến trúc mixture-of-experts.

Bên cạnh bài toán hợp nhất các mô hình tinh chỉnh, còn tồn tại một hướng nghiên cứu với các thiết lập tổng quát hơn, ví dụ như hợp nhất các mô hình được huấn luyện độc lập [17] hay hợp nhất các mô hình có kiến trúc khác nhau [1].

Chương 3

Cơ sở lí thuyết

Chúng ta xét bài toán hợp nhất mô hình sau. Gọi θ_0 là trọng số của mô hình tiền huấn luyện. Xét tập gồm T tác vụ, trong đó mỗi tác vụ tương ứng với một mô hình θ_i được tinh chỉnh từ θ_0 . Mục tiêu của hợp nhất mô hình là kết hợp tri thức học được từ các mô hình tinh chỉnh θ_i vào một mô hình hợp nhất $\hat{\theta}$, sao cho mô hình này vừa duy trì được khả năng tổng quát hóa của mô hình tiền huấn luyện, vừa tích hợp được tri thức chuyên biệt từ từng tác vụ.

Task vectors. Task vector của tác vụ thứ i được định nghĩa như sau: $\tau_i = \theta_i - \theta_0$. Khi đó, một phương pháp hợp nhất hiệu quả [7] là tính trung bình có trọng số của các task vector và cộng kết quả vào mô hình tiền huấn luyện:

$$\hat{\theta} = \theta_0 + \sum_{i=1}^T \lambda_i \circ \phi(\tau_i),$$

trong đó λ_i là hệ số hợp nhất, $\phi(\cdot)$ là một phép biến đổi tùy chọn áp dụng lên task vector, và $\circ$ biểu diễn phép nhân theo từng phần tử (element-wise).

Các hệ số hợp nhất λ_i có thể được định nghĩa ở nhiều mức độ chi tiết khác nhau. Những hướng tiếp cận phổ biến bao gồm: *task-wise*: sử dụng một hệ số duy nhất cho mỗi tác vụ, *layer-wise*: gán một hệ số cho từng tầng của mỗi mô hình. Trong bài báo này, tác giả mở rộng sang thiết lập *element-wise*. Cụ thể, hệ số hợp nhất λ_i có cùng kích thước với tham số mô hình θ_i .

Ký hiệu. Gọi D_i là tập dữ liệu few-shot unlabeled validation¹ cho tác vụ thứ i . Ký hiệu $\varphi(\theta, \cdot)$ thể hiện hàm ánh xạ đặc trưng của mô hình tham số hóa bởi θ , trả về vector embedding của toàn bộ các tầng trung gian trong mô hình. Gọi L là số tầng của mô hình. Với tham số mô hình θ và chỉ số tầng l , θ^l biểu diễn tham số của tầng thứ l , và $\varphi^l(\theta^l, \cdot)$ biểu diễn hàm ánh xạ đặc trưng tương ứng với tầng đó.

¹Tập validation nhỏ không chứa nhãn, chỉ gồm một số ít mẫu đại diện cho mỗi tác vụ downstream.

Chương 4

Giới hạn của nhóm phương pháp hợp nhất mô hình không sử dụng dữ liệu

Các thuật toán hợp nhất mô hình có thể được phân thành hai nhóm chính dựa trên yêu cầu về dữ liệu: **các thuật toán không sử dụng dữ liệu** (*data-agnostic algorithms*), chỉ khai thác trọng số của mô hình tiền huấn luyện và mô hình tinh chỉnh [7]; và **các thuật toán phụ thuộc dữ liệu** (*data-dependent algorithms*) [14]. Mặc dù các phương pháp không sử dụng dữ liệu đã đạt được nhiều thành công đáng kể trong thực nghiệm, bài báo chỉ ra rằng trong trường hợp xấu nhất, hiệu năng các phương pháp này có thể suy giảm mạnh, ngay cả đối với các mô hình tuyến tính đơn giản.

4.1 Giới hạn đối với các mô hình cố định

Xét thiết lập đơn giản cho bài toán hợp nhất mô hình như sau. Giả sử tồn tại hai tác vụ với tập dữ liệu D_1, D_2 , cùng hàm mất mát $l(\cdot, \cdot)$. Gọi f_1, f_2 là hai mô hình cần được hợp nhất, và M là một thuật toán hợp nhất không sử dụng dữ liệu.

Kết quả lý thuyết cho thấy rằng với bất kỳ thuật toán M nào, luôn có thể xây dựng các tập dữ liệu khiến hiệu năng hợp nhất trở nên rất kém.

Định lý 1. *Tồn tại một tác vụ và hàm mất mát l , sao cho với bất kỳ thuật toán hợp nhất không sử dụng dữ liệu M , bất kỳ cặp mô hình $f_1 \neq f_2$, và mọi $\epsilon, C > 0$, luôn tồn tại hai tập dữ liệu D_1, D_2 sao cho f_1, f_2 đạt sai số gần bằng 0 trên tập tương ứng:*

$$l(D_1, f_1) \leq \epsilon, \quad l(D_2, f_2) \leq \epsilon,$$

nhưng mô hình hợp nhất $\hat{f} = M(f_1, f_2)$ lại có sai số lớn trên tập dữ liệu hợp nhất:

$$l(D_1 \cup D_2, \hat{f}) \geq C.$$

Mặt khác, tồn tại một mô hình lý tưởng f^ có sai số gần bằng 0 trên tập dữ liệu hợp nhất:*

$$l(D_1 \cup D_2, f^*) \leq \epsilon.$$

4.2 Giới hạn đối với các mô hình học

Định lý 1 giả định rằng các mô hình f_1 và f_2 cố định. Tuy nhiên giả định này chưa phản ánh đầy đủ các tình huống thực tế, khi các mô hình thường được học trực tiếp từ dữ liệu huấn luyện. Để giải quyết hạn chế này, bài báo mở rộng phân tích sang trường hợp các mô hình được học sử dụng một thuật toán học L , với $f_1 = L(D_1)$, $f_2 = L(D_2)$.

Định lý 2. *Tồn tại một tác vụ, một hàm mất mát l và một thuật toán học L , sao cho với bất kỳ thuật toán hợp nhất không sử dụng dữ liệu M , và mọi $\epsilon, C > 0$, luôn tồn tại hai tập dữ liệu D_1, D_2 sao cho $f_1 = L(D_1)$, $f_2 = L(D_2)$ đạt sai số gần bằng 0 trên tập tương ứng:*

$$l(D_1, f_1) \leq \epsilon, \quad l(D_2, f_2) \leq \epsilon,$$

nhưng mô hình hợp nhất $\hat{f} = M(f_1, f_2)$ lại có sai số lớn trên tập dữ liệu hợp nhất:

$$l(D_1 \cup D_2, \hat{f}) \geq C.$$

Mặt khác, mô hình được học trên tập dữ liệu hợp nhất $f^ = L(D_1 \cup D_2)$ có sai số gần bằng 0 trên tập dữ liệu hợp nhất:*

$$l(D_1 \cup D_2, f^*) \leq \epsilon.$$

Nhận xét 3. Định lý 1 và 2 đều là các phân tích trong trường hợp xấu nhất. Những kết quả này chỉ ra các giới hạn cơ bản của nhóm phương pháp hợp nhất mô hình không sử dụng dữ liệu, nhưng không phủ nhận kết quả thực nghiệm tốt của chúng. Thay vào đó, những định lý trên nhấn mạnh vai trò quan trọng của dữ liệu trong việc đảm bảo tính ổn định và hiệu quả của quá trình hợp nhất mô hình.

Chương 5

Phương pháp: ProDistill

Trong phần trước, tác giả đã chứng minh dữ liệu đóng vai trò quan trọng trong việc hợp nhất mô hình hiệu quả. Dựa trên kết quả này, bài báo đề xuất một thuật toán hợp nhất sử dụng dữ liệu, bắt đầu bằng việc xây dựng một thuật toán chưng cất "ngây thơ" dựa trên việc tối thiểu hóa khoảng cách embedding, sau đó phát triển thành thuật toán chính của bài báo.

5.1 Hợp nhất mô hình dưới góc nhìn Chưng cất tri thức

Bài toán hợp nhất mô hình có thể được tiếp cận dưới góc nhìn của chưng cất tri thức, một hướng nghiên cứu chưa được khai thác nhiều trong cộng đồng. Trong bối cảnh này, các mô hình teacher tương ứng với các mô hình đã được tinh chỉnh, trong khi mục tiêu là xây dựng một mô hình student có khả năng tích hợp tri thức từ các teacher và đạt hiệu năng tốt trên các tác vụ downstream.

Một chiến lược phổ biến trong chưng cất tri thức là căn chỉnh các biểu diễn đặc trưng bên trong giữa teacher và student [25]. Điều này phù hợp với những quan sát gần đây trong lĩnh vực hợp nhất mô hình, cho thấy hiệu năng của mô hình hợp nhất θ có tương quan thuận với mức độ tương đồng giữa embedding của mô hình hợp nhất $\varphi(\theta, x)$ và của các mô hình tinh chỉnh $\varphi(\theta_i, x)$ [28]. Dựa trên nhận định này, bài báo đề xuất căn chỉnh mô hình hợp nhất và các mô hình tinh chỉnh trong không gian đặc trưng bằng cách giải bài toán tối ưu sau:

$$\min_{\lambda_1, \dots, \lambda_T} \sum_{i=1}^T \frac{1}{2T|D_i|} \sum_{x \in D_i} \left\| \varphi \left(\theta_0 + \sum_{j=1}^T \lambda_j \circ \tau_j, x \right) - \varphi(\theta_i, x) \right\|^2. \quad (5.1)$$

Hàm mục tiêu này tối thiểu hóa khoảng cách l_2 giữa embedding của mô hình hợp nhất $\theta_0 + \sum_{j=1}^T \lambda_j \circ \tau_j$ và của từng mô hình tinh chỉnh, trên tập validation không gán nhãn D_i tương ứng với mỗi tác vụ. Về trực giác, điều này khuyến khích mô hình hợp nhất có những hành vi giống với mỗi mô hình tinh chỉnh trong miền dữ liệu riêng của

chúng. Bài toán tối ưu trên có thể giải bằng các thuật toán tối ưu như Adam [10] hoặc AdamW [13] thông qua việc học các hệ số hợp nhất λ_i . Cách tiếp cận tối ưu trực tiếp hàm mục tiêu 5.1 được gọi là DISTILLMERGE.

5.2 Thuật toán ProDistill

Mặc dù phương trình 5.1 là một hàm mục tiêu phù hợp để huấn luyện, việc trực tiếp tối ưu hàm này phát sinh chi phí bộ nhớ rất lớn. Nguyên nhân là do cả task vector và các hệ số hợp nhất cần huấn luyện đều có cùng kích thước với tham số mô hình, và phải được lưu trữ trong bộ nhớ. Bên cạnh đó, chi phí bộ nhớ tăng tuyến tính theo số lượng tác vụ. Ngoài ra, quá trình tối ưu còn yêu cầu lưu trữ các activation trung gian, gradient, và trạng thái của bộ tối ưu, khiến chi phí của bộ nhớ tăng lên đáng kể. Vấn đề này đặc biệt nghiêm trọng đối với các mô hình ngôn ngữ lớn chứa hàng tỷ tham số.

Để giải quyết hạn chế này, bài báo đề xuất một hàm mục tiêu thay thế cho hàm mục tiêu 5.1. Thay vì tối ưu đồng thời toàn bộ mô hình, tác giả áp dụng chiến lược hợp nhất tuần tự theo từng tầng. Cụ thể, với mỗi tầng l ($1 \leq l \leq L$), phương pháp tối thiểu hóa khoảng cách đặc trưng giữa các embedding của tầng tương ứng:

$$\min_{\lambda_1^{(l)}, \dots, \lambda_T^{(l)}} \sum_{i=1}^T \frac{1}{2T|D_i|} \sum_{(z_1, z_2) \in D_i^{(l-1)}} \left\| \varphi^{(l)} \left(\theta_0^{(l)} + \sum_{j=1}^T \lambda_j^{(l)} \circ \tau_j^{(l)}, z_1 \right) - \varphi^{(l)} \left(\theta_i^{(l)}, z_2 \right) \right\|^2 \quad (5.2)$$

So với hàm mục tiêu 5.1, công thức này chỉ tập trung tối ưu khoảng cách embedding ở từng tầng riêng biệt thay vì đồng thời trên toàn bộ mô hình. Một điểm khác biệt quan trọng là phương pháp sử dụng **dual inputs**, cụ thể đưa các embedding khác nhau vào mô hình hợp nhất và mô hình tinh chỉnh. Nói rõ hơn, $D_i^{(l)}$ lưu trữ các cặp embedding (z_1, z_2) sau tầng l , trong đó z_1 là embedding của mô hình hợp nhất, z_2 là embedding của mô hình tinh chỉnh. Các biểu diễn ẩn này được lưu trữ và cập nhật tuần tự sau mỗi tầng dựa trên các hệ số hợp nhất đã học:

$$\begin{aligned} D_i^{(0)} &= \{(x, x) : x \in D_i\}, \\ D_i^{(l)} &= \left\{ \left(\varphi^{(l)} \left(\theta_0^{(l)} + \sum_{j=1}^T \hat{\lambda}_j^{(l)} \circ \tau_j^{(l)}, z_1 \right), \right. \right. \\ &\quad \left. \left. \varphi^{(l)} \left(\theta_i^{(l)}, z_2 \right) \right) : (z_1, z_2) \in D_i^{(l-1)} \right\}, \quad l \geq 1. \end{aligned} \quad (5.3)$$

Thiết kế này cho phép mô hình xấp xỉ tốt hơn hàm tối ưu toàn cục 5.1, khác với các phương pháp hợp nhất mô hình dựa trên căn chỉnh đặc trưng trước đây [9], vốn sử dụng cùng một đầu vào cho cả mô hình hợp nhất và mô hình tinh chỉnh.

Giải thuật này được gọi là PRODISTILL, rút gọn từ *Progressive Layer-wise Distillation*. Mã giả cho PRODISTILL được minh họa ở Thuật toán 1. So với DISTILLMERGE,

PRODISTILL đem lại hiệu quả chi phí tính toán đáng kể. Khi hợp nhất một lớp nhất định, PRODISTILL chỉ yêu cầu bộ nhớ cho task vector τ và hệ số hợp nhất λ cho lớp đó. Ngoài ra, các bước lan truyền tiến và lan truyền ngược cũng đều giới hạn trong các lớp riêng biệt.

Thuật toán 1 PRODISTILL (*Progressive Layer-wise Distillation*)

- 1: **Input:** Pre-trained weights θ_0 , fine-tuned weights θ_i , unlabeled validation sets $\{\mathcal{D}_i\}_{i=1}^T$.
- 2: **Output:** Merging coefficients $\hat{\lambda}_i^{(l)}$, $1 \leq i \leq T, 1 \leq l \leq L$.
- 3: **Initialize** $\mathcal{D}_i^{(0)} = \{(x, x) : x \in D_i\}$, and $\tau_i = \theta_i - \theta_0$ for $i = 1, \dots, T$.
- 4: **for** $l = 1$ to L **do**
- 5: Solve the objective function using gradient descent:

$$\{\hat{\lambda}_i^{(l)}\}_{i=1}^T = \arg \min_{\{\lambda_i^{(l)}\}_{i=1}^T} \sum_{i=1}^T \frac{1}{2T|\mathcal{D}_i|} \sum_{(z_1, z_2) \in \mathcal{D}_i^{(l-1)}} \left\| \varphi^{(l)} \left(\theta_0^{(l)} + \sum_{j=1}^T \lambda_j^{(l)} \circ \tau_j^{(l)}, z_1 \right) - \varphi^{(l)} \left(\theta_i^{(l)}, z_2 \right) \right\|^2$$

- 6: **for** $i = 1$ to T **do**
- 7: Update $\mathcal{D}_i^{(l)}$ using:

$$\mathcal{D}_i^{(l)} = \left\{ \left(\varphi^{(l)} \left(\theta_0^{(l)} + \sum_{j=1}^T \hat{\lambda}_j^{(l)} \circ \tau_j^{(l)}, z_1 \right), \varphi^{(l)} \left(\theta_i^{(l)}, z_2 \right) \right) : (z_1, z_2) \in \mathcal{D}_i^{(l-1)} \right\}$$

- 8: **end for**
 - 9: **end for**
 - 10: **return** $\hat{\lambda}_i^{(l)}$ for $1 \leq i \leq T, 1 \leq l \leq L$.
-

Chương 6

Thực nghiệm và đánh giá

Trong phần này, em trình bày các kết quả thực nghiệm để đánh giá hiệu quả của phương pháp PRODISTILL.

6.1 Thiết lập thực nghiệm

Trong học phần này, em xem xét bài toán hợp nhất mô hình trong bối cảnh tóm tắt văn bản đa miền. Cụ thể, mô hình gốc QWEN3-1.7B [22] được tinh chỉnh độc lập trên ba tập dữ liệu tóm tắt khác nhau, tạo thành ba mô hình chuyên biệt tương ứng cho tóm tắt văn bản miền tin tức, bài báo khoa học, và đoạn hội thoại. Sau đây sẽ gọi các mô hình lần lượt là **Qwen-cnn**, **Qwen-arxiv**, **Qwen-mediasum**.

Mục tiêu của nghiên cứu là hợp nhất ba mô hình này thành một mô hình duy nhất có khả năng duy trì hiệu năng trên cả ba miền dữ liệu mà không cần huấn luyện lại từ đầu.

Dữ liệu. Tương ứng với ba miền tin tức, bài báo khoa học, đoạn hội thoại, em sử dụng các bộ dữ liệu CNN/DailyMail¹, Arxiv², MediaSum³.

Các phương pháp so sánh. Em so sánh phương pháp PRODISTILL với các phương pháp hợp nhất mô hình phổ biến, bao gồm: Task Arithmetic [7], TIES-Merging [21], các biến thể của DARE [26].

Đánh giá. Hiệu năng của các mô hình được đánh giá trên tập kiểm tra của cả ba bộ dữ liệu ở trên. Các độ đo được sử dụng bao gồm:

- ROUGE-1, ROUGE-2, ROUGE-L [12]: đo mức độ trùng khớp giữa bản tóm tắt sinh ra và bản tóm tắt tham chiếu dựa trên các unigram, bigram, và dãy con chung dài nhất.

¹https://huggingface.co/datasets/abisee/cnn_dailymail

²<https://huggingface.co/datasets/ccdv/arxiv-summarization>

³<https://huggingface.co/datasets/ccdv/mediasum>

- BERT-ref, BERT-doc [27]: đánh giá mức độ tương đồng ngữ nghĩa dựa trên biểu diễn từ mô hình BERT. Trong đó, BERT-ref đo độ tương đồng giữa bản tóm tắt sinh ra và bản tóm tắt tham chiếu, còn BERT-doc đo mức độ bảo toàn thông tin giữa bản tóm tắt sinh ra và văn bản nguồn.
- Avg: điểm trung bình của các độ đo trên, được sử dụng như chỉ số tổng hợp để so sánh hiệu năng giữa các mô hình.

6.2 Kết quả thực nghiệm

Em trình bày kết quả hợp nhất ba mô hình **Qwen-cnn**, **Qwen-arxiv**, **Qwen-mediasum** ở bảng 6.1. Kết quả cho thấy phương pháp này hoạt động hiệu quả với các mô hình ngôn ngữ lớn, và đưa lại hiệu năng tốt so với các baselines.

Bảng 6.1: Kết quả so sánh giữa các phương pháp hợp nhất mô hình.

Training Method	CNN/DailyMail	Arxiv	MediaSum	Average
Individual	46.13	45.40	46.12	45.88
Task Arithmetic	44.31	43.29	43.93	43.84
TIES-Merging	45.77	44.39	44.82	44.99
DARE-TIES	44.04	42.71	43.74	43.50
DARE-Linear	44.33	43.36	43.94	43.88
ProDISTILL (Ours)	45.92	44.72	45.84	45.49

Từ kết quả ở Bảng 6.1, có thể thấy ProDISTILL đạt hiệu năng tốt nhất trong số các phương pháp hợp nhất mô hình được so sánh. Cụ thể, ProDISTILL đạt điểm trung bình **45.49** trên ba tập dữ liệu, cao hơn so với các baseline hợp nhất khác. So với Task Arithmetic, phương pháp hợp nhất trực tiếp dựa trên task vector, ProDistill cải thiện 1.65 điểm trung bình.

Xét trên từng miền dữ liệu, ProDISTILL đều đạt kết quả cao nhất trong nhóm các phương pháp hợp nhất. Đặc biệt, trên MediaSum, ProDISTILL đạt 45.84, cao hơn TIES-Merging 1.02 điểm, cho thấy phương pháp này có khả năng bảo toàn hiệu năng tốt hơn trong miền với đặc thù dữ liệu tóm tắt dài như dữ liệu hội thoại.

Một điểm đáng chú ý là ProDISTILL đạt điểm trung bình 45.49, chỉ thấp hơn mô hình Individual 0.39 điểm. Cần nhấn mạnh rằng Individual không phải là một mô hình hợp nhất duy nhất, mà là hiệu năng của từng mô hình chuyên biệt trên miền dữ liệu tương ứng. Vì vậy, Individual có thể được xem như một mốc tham chiếu trên. Việc ProDISTILL tiến gần đến hiệu năng của Individual cho thấy mô hình hợp nhất vẫn giữ lại được phần lớn năng lực chuyên biệt của ba mô hình Qwen-cnn, Qwen-arxiv và Qwen-mediasum, trong khi chỉ cần triển khai một mô hình duy nhất.

Kết quả này cũng cho thấy lợi ích của việc tiếp cận hợp nhất mô hình dưới góc nhìn chưng cất tri thức. Các phương pháp như Task Arithmetic, DARE-Linear hay DARE-TIES chủ yếu thao tác trực tiếp trên task vector mà không sử dụng tín hiệu

đặc trưng từ dữ liệu. Do đó, chúng dễ bị ảnh hưởng bởi xung đột giữa các task vector khi hợp nhất nhiều mô hình đã được tinh chỉnh trên các miền khác nhau. Ngược lại, PRODISTILL sử dụng tập dữ liệu không gán nhãn để căn chỉnh biểu diễn giữa mô hình hợp nhất và các mô hình tinh chỉnh theo từng tầng. Nhờ đó, các hệ số hợp nhất được tối ưu thích nghi hơn với dữ liệu thực tế, giúp giảm suy giảm hiệu năng sau hợp nhất.

Nhìn chung, kết quả thực nghiệm trong Bảng 6.1 chứng minh rằng PRODISTILL là một hướng tiếp cận hiệu quả cho bài toán hợp nhất các mô hình ngôn ngữ lớn trong bối cảnh tóm tắt văn bản đa miền. Phương pháp này không chỉ vượt qua các baseline hợp nhất phổ biến, mà còn duy trì hiệu năng rất gần với các mô hình chuyên biệt, qua đó cho thấy tính khả thi của việc sử dụng chung cốt lõi theo từng tầng để hợp nhất năng lực của nhiều mô hình fine-tuned vào một mô hình duy nhất.

6.3 Phân tích bổ sung

Từ kết quả thực nghiệm như trên, em đưa ra các phân tích bổ sung về giải thuật PRODISTILL trên các khía cạnh hiệu quả sử dụng dữ liệu, và hiệu quả tính toán.


6.3.1 Hiệu quả sử dụng dữ liệu

Đầu tiên, em đánh giá hiệu quả sử dụng dữ liệu của PRODISTILL bằng cách thay đổi số lượng mẫu validation không gán nhãn được sử dụng trong quá trình chưng cất. Cụ thể, số lượng mẫu được thay đổi từ thiết lập không sử dụng dữ liệu đến 64-shot, trong khi số epoch huấn luyện được cố định bằng 50. Kết quả trung bình trên ba tập dữ liệu CNN/DailyMail, Arxiv và MediaSum được trình bày trong Hình 6.1.

Từ kết quả thực nghiệm, có thể thấy PRODISTILL thể hiện khả năng tận dụng dữ liệu rất hiệu quả. Khi không sử dụng dữ liệu validation, PRODISTILL suy biến về thiết lập gần tương đương Task Arithmetic. Tuy nhiên, chỉ cần bổ sung một lượng rất nhỏ dữ liệu validation, hiệu năng của PRODISTILL đã tăng rõ rệt. Với thiết lập 1-shot, điểm trung bình của PRODISTILL đạt khoảng 45.27, vượt qua tất cả các baseline, bao gồm cả TIES-Merging, vốn là baseline mạnh nhất trong Bảng 6.1.

Khi số lượng mẫu validation tăng lên, hiệu năng của PRODISTILL tiếp tục duy trì ở mức cao. Với 2-shot và 4-shot, phương pháp đạt điểm trung bình lần lượt xấp xỉ 45.46 và 45.47, gần tương đương với kết quả tốt nhất ở thiết lập 64-shot. Điều này cho thấy PRODISTILL không yêu cầu nhiều dữ liệu để đạt hiệu quả hợp nhất tốt. Một vài dao động nhỏ khi tăng số lượng mẫu, chẳng hạn tại 16-shot, có thể đến từ tính ngẫu nhiên trong quá trình lấy mẫu validation và đặc thù của từng miền dữ liệu tóm tắt. Tuy nhiên, xu hướng chung vẫn cho thấy PRODISTILL ổn định vượt trội so với các baseline không huấn luyện.

Kết quả này củng cố nhận định rằng dữ liệu đặc thù miền, dù chỉ ở quy mô rất nhỏ, đóng vai trò quan trọng trong bài toán hợp nhất mô hình. Khác với các phương pháp như Task Arithmetic, TIES-Merging hay DARE vốn chỉ thao tác trực tiếp trên task vector, PRODISTILL sử dụng các mẫu validation để căn chỉnh biểu diễn giữa mô hình



Hình 6.1: Kết quả trung bình của PRODISTILL trên 3 tác vụ tóm tắt, với các số lượng mẫu huấn luyện khác nhau. Giải thuật đề xuất chứng minh hiệu quả dữ liệu rất tốt.

hợp nhất và các mô hình tinh chỉnh. Nhờ đó, quá trình học hệ số hợp nhất có thêm tín hiệu từ phân phối dữ liệu thực tế, giúp giảm xung đột giữa các miền và bảo toàn tốt hơn năng lực chuyên biệt của từng mô hình.


6.3.2 Hiệu quả tính toán

Tiếp theo, em đánh giá hiệu quả tính toán của PRODISTILL bằng cách thay đổi số epoch huấn luyện từ 0 đến 100, trong khi số lượng mẫu validation được cố định bằng 64. Kết quả được trình bày trong Hình 6.2.

Có thể thấy PRODISTILL đạt tốc độ hội tụ nhanh. Chỉ sau 1 epoch, điểm trung bình đã tăng mạnh lên khoảng 45.12. Điều này cho thấy phần lớn lợi ích của PRODISTILL xuất hiện ngay ở giai đoạn đầu của quá trình tối ưu, khi các hệ số hợp nhất bắt đầu được điều chỉnh theo tín hiệu chưng cất từ các mô hình tinh chỉnh.

Khi tiếp tục tăng số epoch, hiệu năng của mô hình nhìn chung dao động quanh vùng 45.1 đến 45.5. Kết quả tốt nhất đạt được tại khoảng 50 epoch, với điểm trung bình xấp xỉ 45.49. Sau đó, khi tăng lên 100 epoch, hiệu năng không tiếp tục cải thiện mà giảm nhẹ xuống khoảng 45.10. Hiện tượng này cho thấy việc huấn luyện quá lâu không nhất thiết đem lại lợi ích bổ sung trong thiết lập few-shot, thậm chí có thể khiến mô hình bắt đầu quá khớp với tập validation nhỏ được dùng cho chưng cất.

Kết quả trên cho thấy PRODISTILL có hiệu quả tính toán tốt. Mặc dù là một phương



Hình 6.2: Kết quả trung bình của PRODISTILL với số epoch huấn luyện khác nhau. Giải thuật đạt tốc độ hội tụ nhanh.

pháp có huấn luyện, PRODISTILL không cần số lượng epoch quá lớn để đạt hiệu năng cạnh tranh. Chỉ với một vài epoch đầu, mô hình đã vượt đáng kể so với trạng thái chưa tối ưu, trong khi khoảng 40 đến 50 epoch là đủ để đạt hiệu năng gần tốt nhất trong thiết lập thực nghiệm này. Điều này phù hợp với thiết kế huấn luyện theo từng tầng của PRODISTILL: thay vì tối ưu toàn bộ mô hình theo kiểu end-to-end, phương pháp chỉ huấn luyện hệ số hợp nhất của từng tầng, giúp quá trình tối ưu nhẹ hơn và hội tụ nhanh hơn.

Chương 7

Kết luận

Trong đồ án này, em đã nghiên cứu và triển khai lại phương pháp PRODISTILL cho bài toán hợp nhất mô hình ngôn ngữ lớn trong bối cảnh tóm tắt văn bản đa miền. Cụ thể, em tiến hành hợp nhất ba mô hình Qwen3-1.7B đã được tinh chỉnh trên ba miền dữ liệu khác nhau: CNN/DailyMail, Arxiv và MediaSum. Thay vì chỉ thao tác trực tiếp trên trọng số như các phương pháp hợp nhất không huấn luyện, ProDistill tận dụng một lượng nhỏ dữ liệu validation không gắn nhãn để căn chỉnh biểu diễn giữa mô hình hợp nhất và các mô hình tinh chỉnh theo từng tầng.

Kết quả thực nghiệm cho thấy ProDistill đạt hiệu năng tốt nhất trong số các phương pháp hợp nhất được so sánh, bao gồm Task Arithmetic, TIES-Merging, DARE-TIES và DARE-Linear. Đặc biệt, điểm trung bình của PRODISTILL chỉ thấp hơn mô hình Individual một khoảng nhỏ, cho thấy mô hình hợp nhất vẫn bảo toàn được phần lớn năng lực chuyên biệt của từng mô hình riêng lẻ, trong khi chỉ cần triển khai một mô hình duy nhất. Các phân tích bổ sung cũng cho thấy PRODISTILL có khả năng tận dụng dữ liệu tốt và đạt tốc độ hội tụ nhanh trong thiết lập few-shot.

Tuy nhiên, đồ án vẫn còn một số hạn chế. Thực nghiệm mới được tiến hành trên một mô hình nền và ba bộ dữ liệu tóm tắt văn bản, do đó chưa đánh giá đầy đủ khả năng tổng quát của phương pháp trên nhiều kiến trúc và tác vụ khác nhau. Bên cạnh đó, do giới hạn tài nguyên tính toán, báo cáo chưa phân tích sâu ảnh hưởng của các siêu tham số như learning rate, số epoch, số lượng dữ liệu validation, cũng như các mức độ chi tiết khác nhau của hệ số hợp nhất.

Trong tương lai, có thể mở rộng hướng nghiên cứu này theo một số hướng. Thứ nhất, thử nghiệm ProDistill trên nhiều mô hình nền và nhiều tác vụ sinh ngôn ngữ khác như dịch máy, hỏi đáp hoặc sinh mã nguồn. Thứ hai, đánh giá thêm các biến thể của hệ số hợp nhất như task-wise, layer-wise và element-wise để tìm ra sự đánh đổi phù hợp giữa hiệu năng và chi phí tính toán. Cuối cùng, có thể tiếp tục so sánh hiệu quả của PRODISTILL với những phương pháp hợp nhất khác, đặc biệt là các phương pháp hợp nhất yêu cầu huấn luyện.

Tài liệu tham khảo

- [1] Omri Avrahami, Dani Lischinski, and Ohad Fried. 2022. Gan cocktail: Mixing gans without dataset access. In *Computer Vision – ECCV 2022*, volume 13683 of *Lecture Notes in Computer Science*, pages 205–221, Tel Aviv, Israel. Springer.
- [2] Yoshua Bengio, Pascal Lamblin, Dan Popovici, and Hugo Larochelle. 2006. Greedy layer-wise training of deep networks. In *Advances in Neural Information Processing Systems*, volume 19. MIT Press.
- [3] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, and 12 others. 2020. Language models are few-shot learners. In *Advances in Neural Information Processing Systems*, volume 33, pages 1877–1901, Virtual. Curran Associates, Inc.
- [4] Rich Caruana. 1997. Multitask learning. *Machine Learning*, 28(1):41–75.
- [5] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. 2021. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, Virtual. OpenReview.net.
- [6] Jonathan Frankle, Gintare Karolina Dziugaite, Daniel Roy, and Michael Carbin. 2020. Linear mode connectivity and the lottery ticket hypothesis. In *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 3259–3269. PMLR.
- [7] Gabriel Ilharco, Marco Tulio Ribeiro, Mitchell Wortsman, Suchin Gururangan, Ludwig Schmidt, Hannaneh Hajishirzi, and Ali Farhadi. 2023. Editing models with task arithmetic. In *International Conference on Learning Representations*, Kigali, Rwanda. OpenReview.net.
- [8] Pavel Izmailov, Dmitrii Podoprikin, Timur Garipov, Dmitry Vetrov, and Andrew Gordon Wilson. 2018. Averaging weights leads to wider optima and better

- generalization. In *Proceedings of the Thirty-Fourth Conference on Uncertainty in Artificial Intelligence*, pages 876–885, Monterey, California, USA. AUAI Press.
- [9] Xisen Jin, Xiang Ren, Daniel Preotiuc-Pietro, and Pengxiang Cheng. 2023. Data-less knowledge fusion by merging weights of language models. In *International Conference on Learning Representations*, Kigali, Rwanda. OpenReview.net.
 - [10] Diederik P. Kingma and Jimmy Ba. 2015. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, San Diego, California, USA. OpenReview.net.
 - [11] Thanard Kurutach, Ignasi Clavera, Yan Duan, Aviv Tamar, and Pieter Abbeel. 2018. Model-ensemble trust-region policy optimization. *arXiv preprint arXiv:1802.10592*.
 - [12] Chin-Yew Lin. 2004. ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74–81, Barcelona, Spain. Association for Computational Linguistics.
 - [13] Ilya Loshchilov and Frank Hutter. 2019. Decoupled weight decay regularization. In *International Conference on Learning Representations*, New Orleans, Louisiana, USA. OpenReview.net.
 - [14] Michael S. Matena and Colin A. Raffel. 2022. Merging models with fisher-weighted averaging. In *Advances in Neural Information Processing Systems*, volume 35, pages 17703–17716, New Orleans, Louisiana, USA. Curran Associates, Inc.
 - [15] Guillermo Ortiz-Jimenez, Alessandro Favero, and Pascal Frossard. 2023. Task arithmetic in the tangent space: Improved editing of pre-trained models. In *Advances in Neural Information Processing Systems*, volume 36, pages 66727–66754, New Orleans, Louisiana, USA. Curran Associates, Inc.
 - [16] Biqing Qi, Fangyuan Li, Zhen Wang, Junqi Gao, Dong Li, Peng Ye, and Bowen Zhou. 2025. Less is more: Efficient model merging with binary task switch. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 15265–15274, Nashville, Tennessee, USA. IEEE/CVF.
 - [17] Sidak Pal Singh and Martin Jaggi. 2020. Model fusion via optimal transport. In *Advances in Neural Information Processing Systems*, volume 33, pages 22045–22055, Virtual. Curran Associates, Inc.
 - [18] Derek Tam, Mohit Bansal, and Colin Raffel. 2024. Merging by matching models in task parameter subspaces. *Transactions on Machine Learning Research*.
 - [19] Anke Tang, Li Shen, Yong Luo, Liang Ding, Han Hu, Bo Du, and Dacheng Tao. 2023. Concrete subspace learning based interference elimination for multi-task model fusion. *arXiv preprint arXiv:2312.06173*.

-
- [20] Jing Xu, Jiazheng Li, and Jingzhao Zhang. 2025. Scalable model merging with progressive layer-wise distillation. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, Vancouver, Canada. PMLR.
 - [21] Prateek Yadav, Derek Tam, Leshem Choshen, Colin Raffel, and Mohit Bansal. 2023. TIES-merging: Resolving interference when merging models. In *Advances in Neural Information Processing Systems*, volume 36, New Orleans, Louisiana, USA. Curran Associates, Inc.
 - [22] An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, Chujie Zheng, Dayiheng Liu, Fan Zhou, Fei Huang, Feng Hu, Hao Ge, Haoran Wei, Huan Lin, Jialong Tang, and 41 others. 2025. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*.
 - [23] Enneng Yang, Li Shen, Guibing Guo, Xingwei Wang, Xiaochun Cao, Jie Zhang, and Dacheng Tao. 2026. Model merging in llms, mllms, and beyond: Methods, theories, applications, and opportunities. *ACM Computing Surveys*, 58(8):1–41.
 - [24] Enneng Yang, Zhenyi Wang, Li Shen, Shiwei Liu, Guibing Guo, Xingwei Wang, and Dacheng Tao. 2024. Adamerging: Adaptive model merging for multi-task learning. In *International Conference on Learning Representations*, Vienna, Austria. OpenReview.net.
 - [25] Lucas D. Young, Fitsum A. Reda, Rakesh Ranjan, Jon Morton, Jun Hu, Yazhu Ling, Xiaoyu Xiang, David Liu, and Vikas Chandra. 2022. Feature-align network with knowledge distillation for efficient denoising. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision Workshops*, pages 709–718, Waikoloa, Hawaii, USA. IEEE/CVF.
 - [26] Le Yu, Bowen Yu, Haiyang Yu, Fei Huang, and Yongbin Li. 2024. Language models are super mario: Absorbing abilities from homologous models as a free lunch. In *Proceedings of the 41st International Conference on Machine Learning*, volume 235 of *Proceedings of Machine Learning Research*, pages 57755–57775, Vienna, Austria. PMLR.
 - [27] Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. 2020. BERTScore: Evaluating text generation with BERT. In *International Conference on Learning Representations*, Addis Ababa, Ethiopia. OpenReview.net.
 - [28] Zhanpeng Zhou, Yongyi Yang, Xiaojiang Yang, Junchi Yan, and Wei Hu. 2023. Going beyond linear mode connectivity: The layerwise linear feature connectivity. In *Advances in Neural Information Processing Systems*, volume 36, pages 60853–60877, New Orleans, Louisiana, USA. Curran Associates, Inc.